NSL only-train anomaly detection report

nsl_only_train_anom_nov5 / IsolationForest + OneClassSVM / cc@cc.cc

```
# Rapport détaillé ? NSL-KDD only-train · détection d'anomalies

## 1. Contexte

| Champ | Valeur |
|---|---|
| Plateforme | http://46.62.212.226 |
| Utilisateur | cc@cc.cc |
| Source predefined | nslkdd_only_train_part (125973 lignes) |
| Dataset entraînement | nsl_only_train_anom_nov5 |
| Dataset CSV (Use Model) | nsl_only_train_csv_nov5 (copie brute non modifiée) |
| Target | attack_type |
| Algorithmes | Isolation Forest + One-Class SVM |
| Date | 2026-11-05 22:26 CET |

## 2. Pipeline effectué (étape par étape)

1. Dupliquer le dataset predefined only train ? nsl_only_train_anom_nov5
2. Choisir / sauver la target attack_type
3. Group Optimizer : supprimer toutes les lignes sauf normal (58630 lignes attaque supprimées)
4. Supprimer la colonne difficulty_level
5. Continue (checkpoint)
6. Split 80/20 random (seed=42) ? stratifié impossible car 1 seule classe après filtre
7. Transformation (identique au run classification précédent) :
   - Label Encoding sur attack_type
   - One-Hot sur protocol_type, service, flag
8. Entraîner Isolation Forest puis One-Class SVM, sauvegarder les 2 modèles
9. Nouvelle copie predefined unmodified ? nsl_only_train_csv_nov5
10. Télécharger CSV tel quel (/api/download-dataset-csv)
11. Use Model ? predict-batch sur le CSV avec les 2 modèles sauvegardés

## 3. Stats AVANT preprocessing

- Target metadata: {"target_column": "attack_type", "model_type": "supervised", "is_unsupervised": false}
- Distinct attack_type: 23 / rows 125973

| Valeur | Count |
|---|---:|
| normal | 67343 |
| neptune | 41214 |
| satan | 3633 |
| ipsweep | 3599 |
| portsweep | 2931 |
| smurf | 2646 |
| nmap | 1493 |
| back | 956 |
| teardrop | 892 |
| warezclient | 890 |
| pod | 201 |
| guess_passwd | 53 |
| buffer_overflow | 30 |
| warezmaster | 20 |
| land | 18 |
| imap | 11 |
| rootkit | 10 |
| loadmodule | 9 |
| ftp_write | 8 |
| multihop | 7 |
| phf | 4 |
| perl | 3 |
| spy | 2 |

Filtre appliqué ensuite : garder uniquement attack_type = normal.

## 4. Split & transformation

### Split

| Champ | Valeur |
|---|---|
| Méthode | random 80/20, seed=42 |
| Train | 53874 |
```

Test	13469
Total	67343
Contenu	100% normal (après filtre)

Transformations

- attack_type ? Label Encoding (1 categories)
- protocol_type ? One-Hot Encoding (created 3 new columns)
- service ? One-Hot Encoding (created 26 new columns)
- flag ? One-Hot Encoding (created 10 new columns)
- Colonnes après transform : 78
- Split stats post-transform : train=53874 test=13469

5. Isolation Forest

Hyperparamètres

Paramètre	Valeur
algorithm	isolation_forest
use_scaling	True
random_state	42
n_estimators	100
contamination	0.05
max_samples	auto
max_features	1.0
bootstrap	False

Identité training

Champ	Valeur
Training ID	isolation_forest_1793909939_4e37cca5
Durée	4.1s
Finished	2026-11-05 21:19:03 CET
n_features	77
target_excluded	attack_type
anti_leakage	{'fit_scope': 'train_only', 'scaler_scope': 'train_only', 'test_used_for_fit': False, 'labels_used_for_fit': False, 'labels_fit_note': 'Unsupervised fit on train features only.'}

Résultats train / test (données 100% normal)

Split	n	n_anomalies	anomaly_rate	score_mean	score_min	score_max
train	53874	2694	0.0500	0.1231	-0.1879	0.1772
test	13469	682	0.0506	0.1232	-0.1424	0.1772

Évaluation labels (train set)

Non disponible / non pertinente ici : après filtre, train+test ne contiennent que normal, donc pas de classes positives (attaques) pour precision/recall/F1 sur le split interne.

Sauvegarde modèle

Champ	Valeur
model_id	48
model_name	nsl_iso_normal_nov5
algorithm	isolation_forest
model_type	anomaly
path	/app/saved_models/6a7649c85389ffb49703be24_nsl_iso_normal_nov5_20261105_201903.joblib
saved_at	2026-11-05T20:19:03.873129

Use Model ? prédiction sur CSV brut (125973 lignes)

Champ	Valeur
rows_processed	125973
n_anomaly	56894
n_normal	69079
anomaly_rate	0.4516 (45.2%)
score_min / mean / max	-0.1660 / 0.0205 / 0.1512

pipeline_applied	True
target_column (display only)	attack_type
unexpected columns ignored	['difficulty_level']
chunks	32 × 4000

Note Use Model : le CSV contient encore toutes les classes d'attaque + difficulty_level. Le pipeline sauvegardé (label/one-hot) est réappliqué ; difficulty_level est ignoré ; attack_type n'est pas utilisé comme feature.

6. One-Class SVM

Hyperparamètres

Paramètre	Valeur
algorithm	one_class_svm
use_scaling	True
random_state	42
kernel	rbf
nu	0.05
gamma	scale
degree	3
coef0	0.0
train_on_normals_only	False
normals_filter_applied	False

Identité training

Champ	Valeur
Training ID	one_class_svm_1793909943_5ee4c743
Durée	1m 16s
Finished	2026-11-05 21:20:20 CET
n_features	77
target_excluded	attack_type
anti_leakage	{'fit_scope': 'train_only', 'scaler_scope': 'train_only', 'test_used_for_fit': False, 'labels_used_for_fit': False, 'labels_fit_note': 'Unsupervised fit on train features only.'}

Résultats train / test (données 100% normal)

Split	n	n_anomalies	anomaly_rate	score_mean	score_min	score_max
train	53874	2689	0.0499	23.8371	-54.2884	45.0737
test	13469	713	0.0529	23.8290	-55.2884	41.7476

Évaluation labels (train set)

Non disponible / non pertinente ici : après filtre, train+test ne contiennent que normal, donc pas de classes positives (attaques) pour precision/recall/F1 sur le split interne.

Sauvegarde modèle

Champ	Valeur
model_id	49
model_name	nsl_ocsvm_normal_nov5
algorithm	one_class_svm
model_type	anomaly
path	/app/saved_models/6a7649c85389ffb49703be24_nsl_ocsvm_normal_nov5_20261105_202020.joblib
saved_at	2026-11-05T20:20:20.170806

Use Model ? prédiction sur CSV brut (125973 lignes)

Champ	Valeur
rows_processed	125973
n_anomaly	69507
n_normal	56466
anomaly_rate	0.5518 (55.2%)
score_min / mean / max	-55.2884 / -13.9894 / 30.0683
pipeline_applied	True
target_column (display only)	attack_type
unexpected columns ignored	['difficulty_level']

NSL only-train anomaly detection report

nsl_only_train_anom_nov5 / IsolationForest + OneClassSVM / cc@cc.cc

| chunks | 32 × 4000 |

Note Use Model : le CSV contient encore toutes les classes d'attaque + difficulty_level. Le pipeline sauvegardé (label/one-hot) est réappliqué ; difficulty_level est ignoré ; attack_type n'est pas utilisé comme feature.

7. Synthèse comparative

Modèle	Durée train	Contam./nu	Anomaly rate (train normals)	Anomaly rate (CSV full)	Anomalies CSV
Isolation Forest	4.1s	contamination=0.05	0.0500	0.4516	56894
One-Class SVM	1m 16s	nu=0.05	0.0499	0.5518	69507

8. Interprétation

- Les modèles sont entraînés uniquement sur du trafic normal (one-class / anomaly setting).
- Sur le split interne (aussi 100% normal), le taux d'anomalies ? contamination/nu (~5%) : ce sont des faux positifs attendus sur le profil normal.
- Sur le CSV complet (normal + attaques), le taux d'anomalies monte fortement (IF ? 45.2%, OCSVM ? 55.2%), ce qui est cohérent avec la présence d'attaques dans le fichier brut.
- OCSVM est plus agressif que Isolation Forest sur ce CSV (plus d'anomalies déclarées).

Généré le 2026-11-05 22:26:25 CET